Clasificación de platillos mediante aprendizaje automático

1. Objetivo

El objetivo de esta parte del proyecto es evaluar qué tan bien puede un programa identificar el platillo que aparece en una fotografía utilizando características visuales como el color, la textura y la forma. También se busca reconocer cuáles categorías identifica mejor, en cuáles se equivoca y qué patrones aparecen en esos errores.

2. Modelos utilizados

Se compararon tres modelos de aprendizaje automático supervisado. Los tres utilizan las mismas características de las fotografías, pero aprenden patrones de manera diferente:

Modelo	Descripción
Regresión logística	Traza fronteras rectas entre las categorías de platillos. Es el modelo más sencillo de los tres.
SVM (RBF)	Utiliza fronteras curvas y flexibles para separar las categorías. Puede representar relaciones más complejas, aunque su entrenamiento puede ser más lento.
Random Forest	Combina muchos árboles de decisión. Cada árbol evalúa características y sus resultados se reúnen mediante votación.

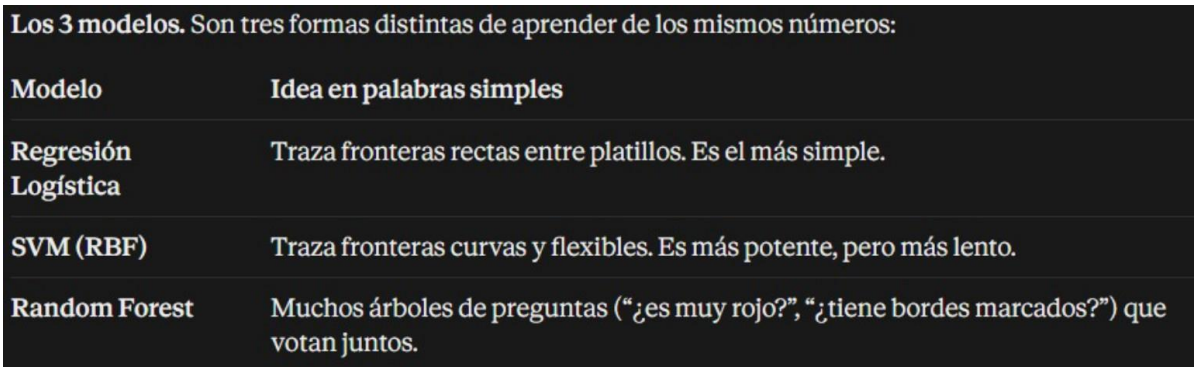


Figura 1. Descripción general de los tres modelos comparados: regresión logística, SVM con kernel RBF y Random Forest.

3. Procedimiento de evaluación

El conjunto de fotografías se dividió en entrenamiento (70 %), validación (15 %) y prueba (15 %). El conjunto de entrenamiento se utilizó para ajustar los modelos; el de validación permitió comparar configuraciones, y el conjunto de prueba se reservó para la evaluación final con imágenes que el modelo no había utilizado durante el aprendizaje.

También se aplicó validación cruzada de 3 pliegues. En este procedimiento, los datos de entrenamiento se separan en tres partes: en cada ronda se entrena con dos partes y se evalúa con la restante; después se cambia la parte utilizada para evaluar. Finalmente, se obtiene el promedio de las tres rondas. Para seleccionar configuraciones se utilizó GridSearchCV, que compara combinaciones de hiperparámetros.

Los valores exactos de los hiperparámetros ganadores no aparecen en la información compartida hasta ahora, por lo que no se incluyen para evitar reportar datos incorrectos.

4. Resultados en el conjunto de prueba

El modelo SVM obtuvo el mejor resultado informado, con 46.7 % de aciertos. Este porcentaje supera el 10 % que correspondería como referencia a una elección aleatoria entre diez categorías. Por lo tanto, el modelo sí aprendió patrones útiles, aunque todavía se equivoca en más de la mitad de las fotografías.

Modelo	**Exactitud en prueba**	**Resultado**
Regresión logística	No proporcionada	Pendiente de completar con la tabla final
SVM (RBF)	46.7 %	Mejor resultado reportado
Random Forest	No proporcionada	Pendiente de completar con la tabla final

5. Análisis de la matriz de confusión

La matriz de confusión permite comparar la categoría real de cada fotografía con la categoría predicha por el modelo. La diagonal representa los aciertos y los valores fuera de ella representan clasificaciones equivocadas. En este proyecto, los resultados por categoría indican que el SVM reconoció mejor la sopa (F1 = 0.713) y el pastel (F1 = 0.574). En cambio, tuvo más dificultades con los tacos (F1 = 0.262) y el omelette (F1 = 0.304).

El valor F1 resume el equilibrio entre precisión y exhaustividad para cada categoría; un valor más alto indica un desempeño más favorable.

6. Confusiones más frecuentes y posibles explicaciones

Platillo real	Predicción equivocada	Cantidad
Tacos	Ensalada César	25 fotografías
Helado	Sushi	23 fotografías
Sushi	Tacos	22 fotografías
Ensalada César	Tacos	21 fotografías
Sushi	Pastel	19 fotografías

Una posible explicación es que algunos platillos compartan colores o texturas, por ejemplo, tonos verdes y rojos en tacos y ensaladas. También podría influir que ciertos alimentos se presenten mezclados, que no tengan una forma claramente definida o que las fotografías cambien mucho en iluminación, distancia y encuadre. Estas explicaciones son hipótesis basadas en los errores observados; no se comprobaron de manera experimental.

7. Conclusión

El SVM con kernel RBF fue el mejor de los tres modelos evaluados, con 46.7 % de aciertos, pero su desempeño muestra que reconocer platillos únicamente con características visuales básicas sigue siendo un reto. Este resultado funciona como línea base para comparar con la CNN de la siguiente entrega y determinar si mejora la clasificación.