Universidad Tecnológica de León
Ser, saber, hacer

11/11/2026

APRENDIZAJE NO SUPERVISADO

Tecnologías de la Información e Innovación Digital
Desarrollo de Software Multiplataforma

Fundamentos de Inteligencia Artificial

Prof.ª Flor Karina Juárez Cárdenas

ANGEL EZEQUIEL MEDEL VAZQUEZ
LDSM705

Análisis del aprendizaje no supervisado

El objetivo de este apartado fue evaluar si un algoritmo podía identificar agrupaciones de imágenes de alimentos de acuerdo con sus características visuales, sin recibir previamente información sobre el nombre o la categoría de cada platillo. A diferencia del aprendizaje supervisado, en este procedimiento no se utilizaron las etiquetas reales para entrenar el modelo, sino que se permitió que el algoritmo encontrara patrones y similitudes por sí mismo.

Para realizar este análisis se utilizaron dos técnicas complementarias: PCA (Análisis de Componentes Principales) y GMM (Modelos de Mezclas Gaussianas). Posteriormente, los grupos obtenidos se compararon con las categorías reales para evaluar qué tan similares eran las agrupaciones generadas por el algoritmo a las que se utilizarían en una clasificación convencional.

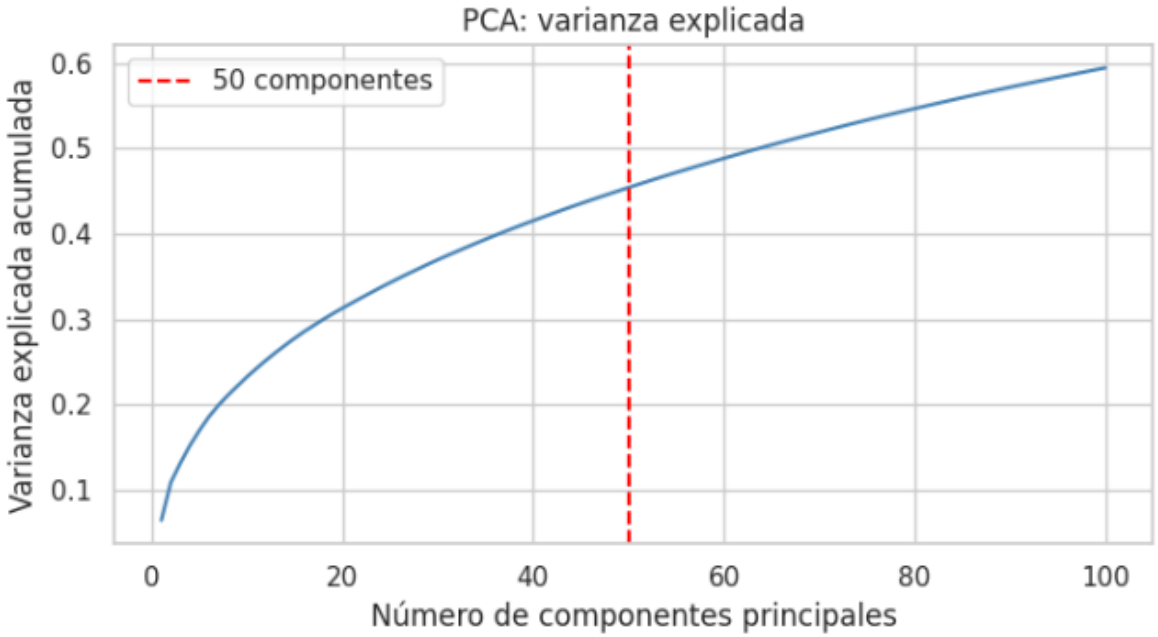
Preparación de los datos y aplicación de PCA

Inicialmente, cada imagen fue representada mediante 1,932 características numéricas relacionadas con aspectos como el color, la textura y la forma. Sin embargo, trabajar con una cantidad tan elevada de características puede dificultar el procesamiento y aumentar la complejidad del análisis.

Para reducir esta dimensionalidad se utilizó PCA, una técnica que transforma las características originales en un conjunto menor de componentes principales, conservando la mayor cantidad posible de variabilidad de los datos.

En este proyecto, las 1,932 características originales se redujeron a 50 componentes principales, con los cuales se conservó el 45.4 % de la varianza explicada. Esto significa que el nuevo conjunto representa una parte importante de los patrones presentes en los datos originales, aunque también deja fuera una proporción considerable de su variabilidad.

La reducción permitió trabajar con una representación más compacta de las 10,000 imágenes. Es importante señalar que el 45.4 % de varianza explicada no representa un porcentaje de aciertos del modelo, sino la proporción de variabilidad de los datos originales que conserva la transformación PCA.




```
Con 50 componentes se conserva el 45.4% de la varianza.
Forma después de PCA: (10000, 50)
```

Se seleccionaron 50 componentes para conservar el 45.4 % de la varianza original.

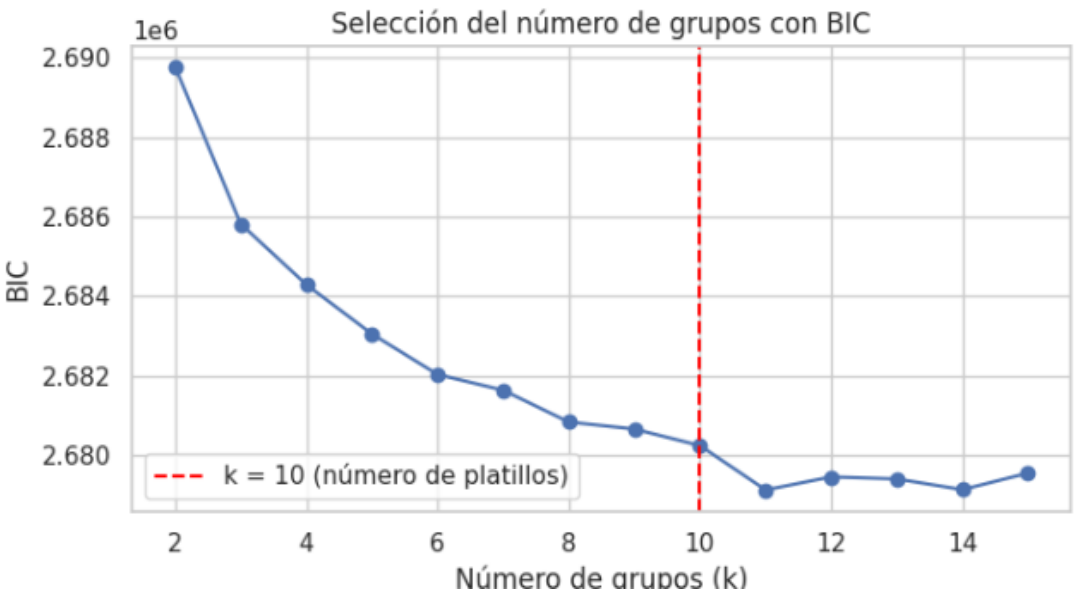
Agrupamiento mediante GMM y selección del número de grupos

Una vez reducida la dimensionalidad, se utilizó GMM (Gaussian Mixture Models) para realizar el agrupamiento de las imágenes.

GMM es un algoritmo de aprendizaje no supervisado que identifica grupos o *clusters* a partir de la distribución de los datos. En este caso, el modelo analizó las características visuales de las imágenes y las agrupó de acuerdo con sus similitudes, sin conocer previamente si una fotografía correspondía a una pizza, un sushi, una ensalada u otro platillo.

Para determinar cuántos grupos utilizar se aplicó el criterio BIC (Bayesian Information Criterion). Este indicador evalúa qué tan bien se ajusta un modelo a los datos y penaliza la complejidad innecesaria. Por lo tanto, un valor BIC menor representa una mejor combinación entre ajuste y complejidad.

Se probaron diferentes cantidades de grupos, desde 2 hasta 15. El valor más bajo del BIC se obtuvo con 11 grupos. No obstante, para la comparación final se estableció GMM con 10 grupos, debido a que el conjunto de datos contiene 10 categorías reales de platillos. De esta manera, se facilitó la comparación entre los grupos generados por el algoritmo y las categorías originales.



Cabe aclarar que el resultado del BIC fue de 11 grupos, por lo que utilizar 10 fue una decisión tomada para facilitar la evaluación, no porque el criterio BIC hubiera seleccionado esa cantidad como la óptima.

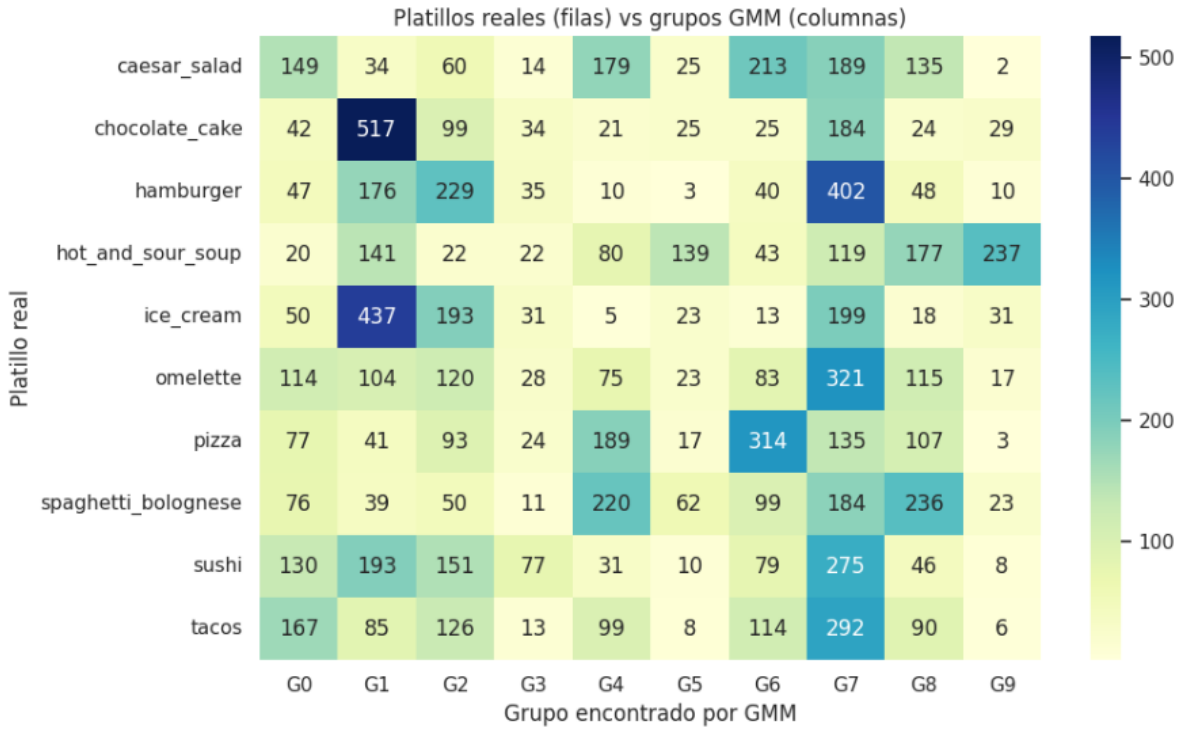
Comparación de los grupos con los platillos reales

Después de obtener los grupos mediante GMM, se compararon los resultados con las categorías originales del conjunto de datos. Aunque las etiquetas reales no participaron en el entrenamiento, se utilizaron posteriormente para interpretar y evaluar las agrupaciones.

Para ello se generó una tabla cruzada que relaciona los platillos reales con los grupos identificados por el algoritmo. En esta tabla, las filas representan las categorías originales y las columnas corresponden a los grupos generados por GMM. Cada celda indica cuántas imágenes de determinado platillo fueron asignadas a un grupo específico.

Si el algoritmo hubiera identificado correctamente las categorías, se esperaría que las imágenes de cada platillo se concentraran principalmente en un solo grupo. Sin embargo, en los resultados se observó que las fotografías de varios platillos se distribuyeron entre diferentes grupos. Esto indica que el algoritmo tuvo dificultades para reconocer agrupaciones que coincidieran con las categorías reales.

Además de la tabla cruzada, se calcularon tres métricas para medir el nivel de correspondencia entre los grupos generados y las etiquetas originales:



Demuestra cómo se distribuyeron las imágenes de cada platillo entre los grupos encontrados. Permite observar que muchas categorías se repartieron entre varios grupos.

Pureza (Purity): 0.254

La pureza mide qué proporción de imágenes pertenece a la categoría predominante dentro de cada grupo. Para calcularla se identifica la categoría real con más imágenes en cada grupo y se suman esas cantidades. El resultado se divide entre el total de imágenes.

En este proyecto se obtuvo una pureza de 0.254, equivalente al 25.4 %. Esto indica que una proporción reducida de las imágenes quedó agrupada con otras de su misma categoría predominante. Por lo tanto, existe una correspondencia baja entre los grupos generados y los platillos reales.

Adjusted Rand Index (ARI): 0.060

El ARI mide el grado de coincidencia entre dos agrupaciones, considerando tanto las imágenes que se colocan juntas como aquellas que se mantienen separadas. Su valor se interpreta de la siguiente manera: un resultado cercano a 1 indica una coincidencia elevada; un valor cercano a 0 indica una correspondencia similar a la esperada por azar; y un valor negativo indica una coincidencia inferior a esa referencia.

El resultado obtenido fue de 0.060, lo que representa una correspondencia muy baja entre las agrupaciones de GMM y las categorías originales.

Normalized Mutual Information (NMI): 0.116

La información mutua normalizada mide cuánta información comparten dos agrupaciones. En este caso, permite conocer qué tanto se relacionan los grupos identificados por GMM con las categorías reales de los platillos. Sus valores se encuentran entre 0 y 1: cuanto más cercano a 1, mayor es la relación entre ambas agrupaciones.

El resultado fue de 0.116, lo que indica que existe poca información compartida entre los grupos generados y las categorías originales.

En conjunto, las tres métricas muestran que el agrupamiento no logró reproducir de manera satisfactoria las categorías reales de los alimentos. Sin embargo, esto no significa que el procedimiento haya fallado por un error de programación, sino que los patrones visuales utilizados no fueron suficientes para obtener una separación clara entre todos los tipos de platillos.

Una posible explicación es que diferentes alimentos pueden compartir características de color, textura y forma, mientras que un mismo platillo puede presentar variaciones importantes dependiendo de su preparación, presentación, iluminación o fotografía. También debe considerarse que PCA conservó únicamente el 45.4 % de la varianza, por lo que parte de la variabilidad original no estuvo presente en el agrupamiento.

Visualización de los resultados en dos dimensiones

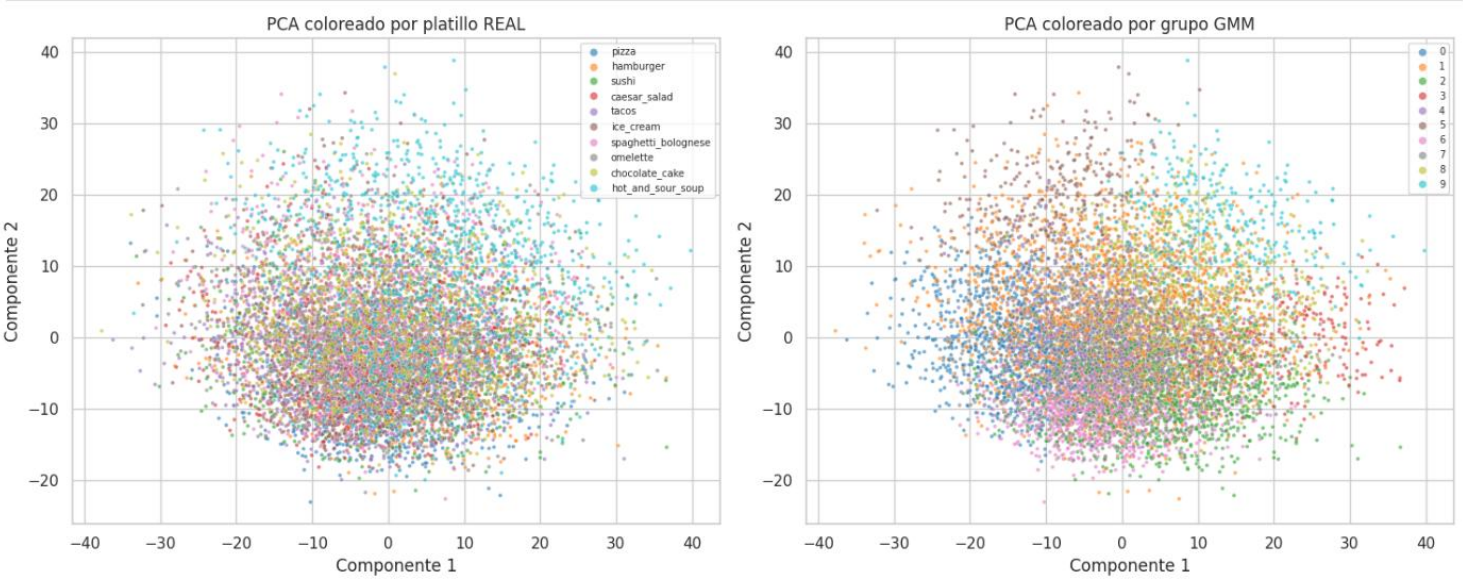
Para facilitar la interpretación de los resultados se generaron dos gráficas de dispersión utilizando los dos primeros componentes principales de PCA.

En la primera gráfica, las imágenes se colorearon de acuerdo con sus categorías reales. En la segunda, se colorearon de acuerdo con los grupos identificados por GMM.

Esta comparación permite observar visualmente cómo se distribuyen las imágenes y qué tan bien coinciden las agrupaciones generadas con las categorías originales. La separación poco definida entre los grupos es consistente con los valores bajos obtenidos en las métricas de evaluación.

Es importante mencionar que estas gráficas utilizan únicamente los dos primeros componentes principales para representar los datos en un plano. Sin embargo, el modelo GMM realizó el agrupamiento utilizando los 50 componentes obtenidos

mediante PCA, por lo que la visualización es una representación simplificada del espacio utilizado por el algoritmo.



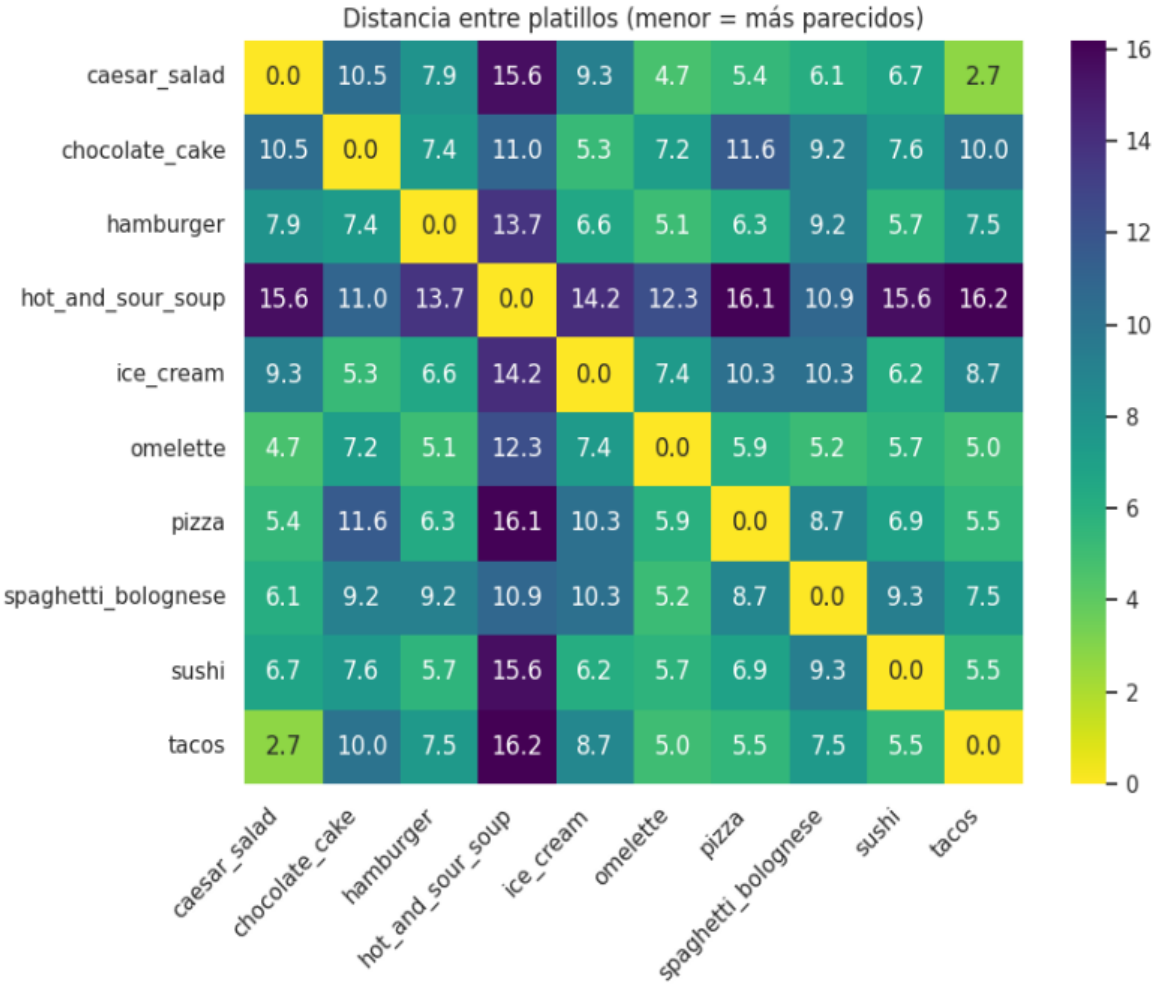
Permiten comparar visualmente la distribución de las fotografías según sus categorías originales y según los grupos encontrados por GMM.

Similitud entre platillos mediante la matriz de distancias

Además de evaluar los grupos de GMM, se realizó un análisis de similitud visual entre las categorías originales.

Para ello se calculó el centro de cada platillo en el espacio de 50 componentes principales. Este centro corresponde al promedio de las representaciones numéricas de todas las imágenes pertenecientes a una misma categoría. Posteriormente, se calcularon las distancias euclidianas entre dichos centros.

La matriz de distancias permite identificar qué platillos presentan representaciones visuales más cercanas. En ella, los valores pequeños indican mayor similitud, mientras que los valores elevados representan una mayor diferencia entre las características promedio de los platillos.



Los cinco pares con menor distancia fueron los siguientes:

Platillos	Distancia
Caesar salad y tacos	2.7
Caesar salad y omelette	4.7
Omelette y tacos	5.0
Hamburger y omelette	5.1
Omelette y spaghetti bolognese	5.2

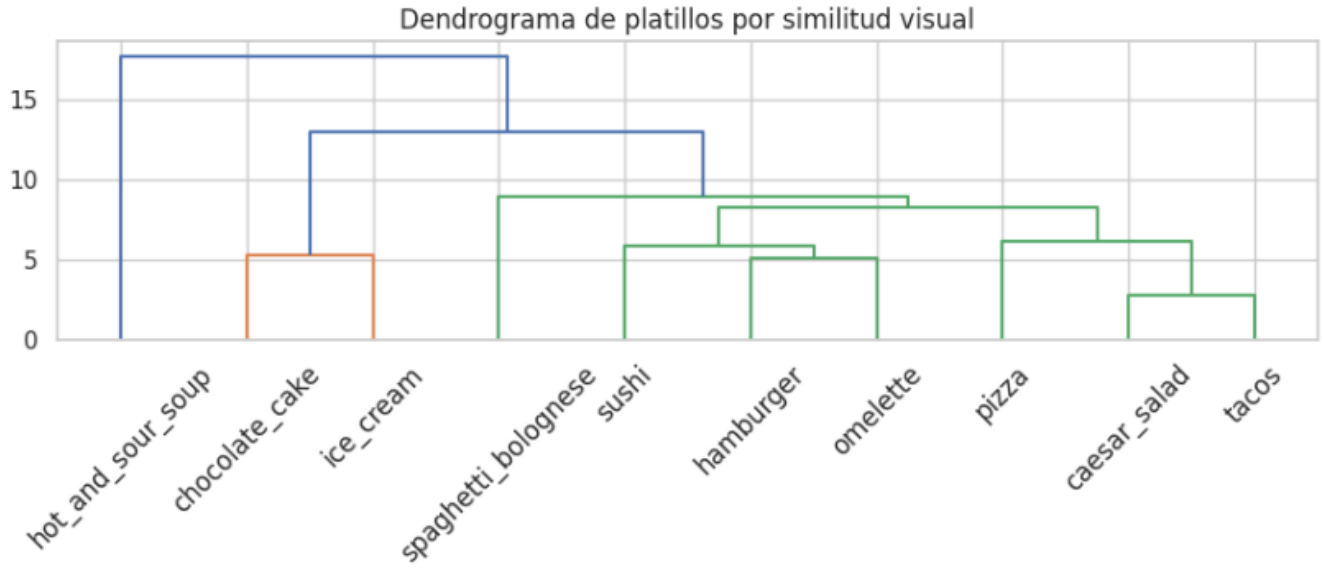
El par más cercano fue ensalada César y tacos, con una distancia de 2.7. Esto indica que, dentro de la representación utilizada, ambos platillos presentan características visuales promedio similares.

También se identificó cierta proximidad entre la ensalada César, el omelette y los tacos, lo que sugiere que el algoritmo encontró similitudes entre sus representaciones. Sin embargo, esto no significa que sean alimentos equivalentes desde el punto de vista gastronómico, sino que sus características visuales, tal como fueron representadas por los datos, tienen una distancia relativamente pequeña.

Por otra parte, la sopa agridulce (*hot and sour soup*) presentó un comportamiento visual más diferenciado respecto a los demás platillos, lo que también se refleja en su separación dentro de la propuesta jerárquica.

Propuesta de agrupación del menú mediante el dendrograma

Finalmente, se utilizó un dendrograma para representar las relaciones de similitud entre los platillos. Este gráfico se construyó mediante agrupamiento jerárquico utilizando el método de Ward, el cual reúne progresivamente los elementos buscando minimizar el incremento de la variabilidad dentro de los grupos.




```
Propuesta de menú agrupado en 4 secciones por similitud visual:
   Sección 1: chocolate_cake, ice_cream
   Sección 2: caesar_salad, hamburger, omelette, pizza, sushi, tacos
   Sección 3: spaghetti_bolognese
   Sección 4: hot_and_sour_soup
```

Muestra las relaciones jerárquicas entre las categorías y cómo se obtuvo la propuesta de dividir el menú en cuatro secciones.

A partir del dendrograma se estableció una propuesta de menú dividida en cuatro secciones:

Sección	Platillos
1	Chocolate cake, ice cream
2	Caesar salad, hamburger, omelette, pizza, sushi, tacos
3	Spaghetti bolognese
4	Hot and sour soup

La propuesta presenta algunos resultados que tienen sentido desde una perspectiva visual. Por ejemplo, agrupar el pastel de chocolate y el helado en una misma sección resulta razonable, ya que ambos pertenecen a la categoría de postres y presentan características visuales que pueden ser similares.

También destaca que la sopa agridulce quedó en una sección independiente, lo cual puede explicarse por sus características particulares de presentación y apariencia en comparación con los demás alimentos.

Sin embargo, la segunda sección reúne una cantidad considerable de platillos diferentes, como ensalada César, hamburguesa, omelette, pizza, sushi y tacos. Aunque pueden compartir algunas características visuales, gastronómicamente son alimentos bastante distintos. Por ello, esta agrupación resulta demasiado general para utilizarse directamente como una clasificación definitiva de un menú.

Por otro lado, el espagueti a la boloñesa quedó como una categoría individual. Esta separación es discutible, ya que en el dendrograma se observa que termina uniéndose al grupo más grande a una distancia aproximada de 9. Esto indica que no se encuentra completamente aislado de los demás platillos, aunque tampoco presenta una similitud suficientemente cercana para compartir una sección con ellos cuando se establece el corte en cuatro grupos.

En consecuencia, la propuesta de menú tiene sentido de manera parcial: identifica algunas similitudes visuales razonables, como la agrupación de los postres, pero también produce secciones demasiado generales o categorías individuales que no necesariamente representan una organización gastronómica adecuada.

Debe considerarse que esta propuesta se construyó exclusivamente con características visuales. No se analizaron ingredientes, métodos de preparación, sabores ni el tipo de comida al que pertenece cada platillo. Por esta razón, el resultado debe interpretarse como una sugerencia de agrupación visual y no como una clasificación culinaria definitiva.

Conclusión del apartado

El análisis de aprendizaje no supervisado permitió comprobar que es posible utilizar técnicas de reducción dimensional y agrupamiento para explorar similitudes entre imágenes de alimentos sin proporcionar previamente sus categorías.

PCA facilitó el procesamiento de las 10,000 imágenes al reducir sus 1,932 características originales a 50 componentes principales. Posteriormente, GMM identificó 10 grupos a partir de las representaciones reducidas. Sin embargo, al comparar estos resultados con las categorías reales se obtuvieron valores bajos de pureza (0.254), ARI (0.060) y NMI (0.116), lo que demuestra que los grupos encontrados no coincidieron significativamente con los platillos originales.

El análisis permitió identificar relaciones interesantes entre algunos alimentos. La matriz de distancias mostró que la ensalada César y los tacos fueron los platillos con mayor similitud visual entre sus centros, mientras que el dendrograma permitió proponer una organización del menú en cuatro secciones.

El procedimiento no logró clasificar los alimentos de la misma manera en que lo haría una persona utilizando sus categorías, pero sí permitió descubrir patrones y similitudes visuales presentes en las imágenes. Esto demuestra una de las características principales del aprendizaje no supervisado, puede encontrar estructuras en los datos sin conocer previamente su significado, aunque los grupos obtenidos no necesariamente coincidan con las categorías que las personas consideran correctas.