1. Introducción

ChefBot es un robot mesero simulado que tiene la capacidad de reconocer platillos a partir de una fotografía para luego entregarlos a la mesa correcta dentro de un restaurante.

El principal problema que resuelve es la necesidad de que una persona le indique al robot qué platillo lleva. Al integrar un sistema de visión y clasificación, el robot puede identificar por sí solo la orden que está transportando, volviendo todo el proceso mucho más autónomo y eficiente.

En esta primera entrega del proyecto, nos enfocamos en preparar los datos base utilizando un subconjunto del dataset Food-101, seleccionando 10 clases de platillos (aproximadamente 10,000 imágenes).

Extrajimos sus características principales y utilizamos esos datos para clasificar las imágenes usando 3 modelos clásicos de aprendizaje automático. Además, implementamos técnicas como PCA y GMM para agrupar los platillos que son visualmente similares.

2. Metodología de características

Un modelo clásico de aprendizaje automático no puede analizar una fotografía directamente, ya que solo trabaja con tablas de números. Una imagen de 128×128 a color tiene decenas de miles de valores de píxeles sueltos que no le dicen al modelo si algo es verde o redondo. Por ello, fue necesario resumir cada foto en una lista más corta de números que describa lo importante, conocida como vector de características. Al final de este proceso, cada fotografía quedó representada por una lista exacta de 1,932 números.

Para el análisis del color utilizamos los histogramas HSV (tono, saturación y brillo). Esta característica resume la "huella de color" de la imagen y genera 128 números. Por ejemplo, puede ayudar a identificar una ensalada César por sus múltiples píxeles verdes, o distinguirla de una sopa agridulce que tiene tonos rojizos o marrones.

Para la textura, aplicamos la matriz GLCM, que evalúa qué tan distintos son los píxeles vecinos entre sí (generando 40 números). Esto permite distinguir la suavidad de las superficies; por ejemplo, puede ayudar a diferenciar la apariencia lisa y uniforme de un helado frente a los múltiples cambios y detalles que presenta un plato de espagueti o unos tacos.

Finalmente, para la forma, usamos los descriptores HOG, los cuales detectan los bordes y la dirección hacia la que apuntan. Dado que analiza la imagen por cuadrículas, esta es la característica más grande, aportando 1,764 números. El HOG sirve para describir los contornos, lo que puede ayudar a que el modelo distinga que una pizza es redonda mientras que una hamburguesa tiene capas y líneas horizontales.

Decidimos combinar estas tres características (128 + 40 + 1,764 = 1,932 números) porque ninguna basta por sí sola para describir un platillo. El color podría confundir un pastel de chocolate con un helado de chocolate; la textura podría confundir dos alimentos lisos distintos; y la forma sola no diferencia platillos con contornos similares. Juntas brindan una descripción mucho más completa que permite separar los platillos con mayor precisión.

3. Tareas realizadas por el equipo

Integrante	Rol	Tareas
Alvaro	Líder de proyecto y datos	Ejecutó el notebook, análisis exploratorio, sección de Datos, repositorio y README
Jose	Responsable de CNN	Introducción, metodología de características, tabla de tareas
Adan	Responsable de ML clásico	Análisis de clasificación (sección 3)
Angel	Responsable de refuerzo e integración	Análisis de agrupamiento (sección 4)